

Company Data Enrichment - Code Explanation

1. Mục tiêu của module

company_data_enrichment là pipeline tiền xử lý cho Entity Resolution. Module đọc dataset công ty, lấy URL chính thức và social, crawl web bằng Crawl4AI, trích xuất evidence, validate country/city, merge dữ liệu vào bản enriched và xuất file gọn data_er_ready.csv cho bước ER tiếp theo.

Code hiện tại không dùng Spark. Toàn bộ xử lý local đang dựa trên pandas, Crawl4AI, BeautifulSoup và các rule tự định nghĩa trong Python.

Thiết kế chính

- Giữ schema chuẩn trong target_fields, rồi map nhiều format web khác nhau về schema này.
- Crawl4AI vẫn là crawler chính. BeautifulSoup chỉ dùng để parse HTML/JSON-LD/meta tags sau khi đã crawl.
- Country code được chuẩn hoá ISO-2, ví dụ main_country_code = US và main_country = United States.
- TLD mạnh như .dk, .se, .de có thể lock country/country_code sớm, nhưng crawler vẫn chạy để enrich các field khác.
- Official website được deep crawl; social URL vẫn giữ trong manifest nhưng chỉ crawl trang seed, không deep crawl.
- Crawler hiện chia batch để tránh một Playwright/Chromium context phải sống xuyên suốt hàng nghìn URL.

2. Cấu trúc file

File	Vai trò
config/company_data_enrichment.yaml	Cấu hình input/output, URL columns, crawl, validation, ER-ready thresholds và target_fields.
src/company_data_enrichment/pipeline.py	Orchestrator chính: build-manifest, crawl, extract, merge, export-er-ready, run-all.
src/company_data_enrichment/crawler.py	Crawl4AI wrapper: browser config, deep crawl, URL filter, batch restart, flatten result.
src/company_data_enrichment/extractors.py	Parse HTML/markdown bằng BeautifulSoup, JSON-LD, meta tags, regex email/phone/year/employee.
src/company_data_enrichment/geo_signals.py	Country/city inference, ISO normalization, TLD/language/text signals, voting verdict.
src/company_data_enrichment/url_manifest.py	Chuẩn hoá URL, tạo manifest và crawl queue từ các cột URL.
src/company_data_enrichment/rules.py	Rule engine quyết định KEEP, ADD, REPLACE, CONFLICT_REVIEW.
src/company_data_enrichment/pandas_io.py	Hàm đọc/ghi CSV và Parquet bằng pandas.
src/company_data_enrichment/quality_report.py	Tạo báo cáo chất lượng sau merge.
test/	Unit tests cho crawler, extractor, geo signals, pipeline, rules và I/O.

3. Input và config

Input chính là file CSV tại dataset/data_sample_AofAI.csv. File này chứa thông tin công ty ban đầu, các cột main_* hiện có, website_url, website_tld, website_language_code và các social URL như linkedin_url, facebook_url, instagram_url, twitter_url, youtube_url.

```

input_csv: dataset/data_sample_AofAI.csv
output_dir: dataset/silver

url_columns:
  website_url: official
  linkedin_url: social
  facebook_url: social
  instagram_url: social
  twitter_url: social
  youtube_url: social

crawl:
  max_concurrency: 3
  crawl_batch_size: 100
  timeout_ms: 60000
  retry_count: 2
  deep_crawl_enabled: true
  deep_crawl_max_depth: 1
  deep_crawl_max_pages: 5
  deep_crawl_include_external: false

```

Crawl config	Ý nghĩa
max_concurrency: 3	Số URL/page được crawl song song trong cùng một batch. Giá trị 3 giúp chạy nhanh hơn crawl tuần tự nhưng vẫn không mở quá nhiều tab Chromium cùng lúc.
crawl_batch_size: 100	Số seed URL xử lý trước khi restart AsyncWebCrawler/Chromium context. Giá trị 100 giúp tránh lỗi context sống quá lâu như pipe closed by peer hoặc Browser.close failure.
timeout_ms: 60000	Thời gian chờ tối đa cho một page crawl, tính bằng milliseconds. 60000 nghĩa là 60 giây trước khi coi page đó là timeout.
retry_count: 2	Số lần Crawl4AI được phép thử lại khi một URL fail. Hữu ích với lỗi tạm thời, nhưng làm crawl lâu hơn nếu website thật sự chặn hoặc không tồn tại.
deep_crawl_enabled: true	Bật chế độ crawl sâu. Trong code hiện tại chỉ official website được deep crawl; social URL vẫn bị ép single-page để giảm block.
deep_crawl_max_depth: 1	Độ sâu link nội bộ tối đa từ seed URL. Depth 1 nghĩa là crawl trang gốc và các link nội bộ trực tiếp như about/contact/product.
deep_crawl_max_pages: 5	Số page tối đa cho mỗi official seed URL. Giá trị 5 thường tương đương trang gốc + tối đa 4 trang nội bộ liên quan.
deep_crawl_include_external: false	Không đi sang domain ngoài. Cài đặt này tránh crawler lan sang social, CDN, quảng cáo, tracking hoặc website không thuộc công ty.

target_fields là schema chuẩn mà pipeline muốn enrich và audit. Các extractor có thể lấy dữ liệu từ JSON-LD, meta tags, body text hoặc CSV signals, nhưng cuối cùng đều map về các field này.

```

target_fields:
  - company_name
  - company_legal_names
  - company_commercial_names
  - main_country_code
  - main_country
  - main_region
  - main_city
  - main_postcode
  - main_street
  - primary_email
  - primary_phone
  - short_description
  - year_founded
  - employee_count

```

4. Cách chạy


```
PYTHONPATH=src python -m company_data_enrichment.pipeline build-manifest
PYTHONPATH=src python -m company_data_enrichment.pipeline crawl
PYTHONPATH=src python -m company_data_enrichment.pipeline extract
PYTHONPATH=src python -m company_data_enrichment.pipeline merge
PYTHONPATH=src python -m company_data_enrichment.pipeline export-er-ready
```

Chạy toàn bộ:

```
PYTHONPATH=src python -m company_data_enrichment.pipeline run-all
```

Chạy thớt ít URL:


```
PYTHONPATH=src python -m company_data_enrichment.pipeline run-all --limit 10
```

Test:

```
PYTHONPATH=src pytest -q
```

5. Flow chi tiết

Luồng xử lý tổng quát



Outputs:

url_manifest, crawl_results_raw, crawl_extracted_fields, company_validation_results, data_enriched, data_er_ready.

Step 1: build-manifest

run_build_manifest đọc CSV gốc, tạo url_manifest.parquet, crawl_queue.parquet và geo_prefill.parquet. Manifest giữ quan hệ giữa company ID, URL, source type và priority. Queue là danh sách URL seed để crawler xử lý.

- official: website_url, được phép deep crawl.
- social: LinkedIn/Facebook/Instagram/Twitter/YouTube, vẫn crawl nhưng chỉ trang đầu.
- geo_prefill: nếu website_tld hoặc website_url có TLD mạnh, pipeline tạo locked evidence cho main_country_code và main_country.

Ví dụ: website_url = https://example.dk hoặc website_tld = dk sẽ tạo evidence main_country_code = DK và main_country = Denmark. Evidence này được lock vì .dk là country-specific TLD. Crawler vẫn chạy để lấy city, email, phone, description, year_founded và employee_count.

Step 2: crawl

run_crawl đọc crawl_queue.parquet rồi gọi Crawl4AI. Official URL dùng BFSDeepCrawlStrategy với depth mặc định 1 và max 5 pages mỗi seed URL. Social URL bị ép deep_crawl_enabled = false, nên thường depth = 0.

Crawler hiện có crawl_batch_size = 100. Điều này giúp restart AsyncWebCrawler theo batch để Playwright/Chromium context không phải sống trong toàn bộ 5000+ URL. Nếu một social/YouTube page làm context lỗi, kết quả batch khác vẫn được giữ.

```
CrawlerRunConfig:
  wait_until = domcontentloaded
  delay_before_return_html = 2.0
  page_timeout = 60000
  remove_overlay_elements = True
  remove_consent_popups = True
  simulate_user = True
  override_navigator = True
  magic = True
  scan_full_page = True
  max_scroll_steps = 3
  max_retries = 2
```

Output crawl_results_raw.parquet có schema chính: seed_url, canonical_url, domain, depth, source_type, source_col, priority, success, fetched_at, markdown, html, metadata_json, error_message.

Các lỗi như DNS fail, anti-bot, CAPTCHA, LinkedIn/YouTube block, hoặc BrowserContext.new_page fail được ghi thành success=False cho URL/page đó. Pipeline không crash vì lỗi từng URL.

Step 3: extract

run_extract đọc crawl_results_raw.parquet. extractors.py dùng BeautifulSoup để parse HTML, xoá script/style/nav/footer/header/aside khỏi clean text, rồi trích xuất field evidence.

- JSON-LD Organization/Corporation/LocalBusiness: name, legalName, email, telephone, address, foundingDate/foundingYear, numberOfEmployees.
- Meta tags: title, description, geo.region, geo.placename, og:locale, language/html lang.
- Plain text/markdown: regex cho email, phone, founded year, employee count, country/city text signals.
- Failed crawl row vẫn có thể được extract nếu còn html hoặc markdown.

run_extract cũng sinh CSV-based evidence từ website_tld và website_language_code. TLD evidence mạnh hơn language evidence. Sau đó build_company_validation_results tạo company_validation_results.csv/parquet từ chính input CSV + crawl evidence, không dùng candidate_validation_v2.csv.

Step 4: country validation

geo_signals.py gom các tín hiệu country từ TLD, language, JSON-LD, meta/text web và social. Các signal được vote theo trọng số. Strong TLD và JSON-LD thường mạnh hơn language/html locale.

Verdict	Ý nghĩa
CONFIRMED	Country gốc khớp với country được vote.
MISSING_FILLED	Country gốc thiếu, validation có đủ confidence để fill.
CONFLICT_TLD	Country-specific TLD mâu thuẫn với country gốc, đề xuất correct.
CONFLICT	Web/JSON-LD/text vote mâu thuẫn với country gốc và đủ confidence.
CONFLICT_UNCERTAIN	Có mâu thuẫn nhưng confidence thấp, nên review.
insufficient_data	Không đủ evidence để quyết định.

Weak locale policy nằm trong config. Ví dụ en, en-US, english có thể bị xem là signal yếu nếu không có evidence hỗ trợ, tránh việc mọi website tiếng Anh bị suy ra United States.

Step 5: merge

run_merge chọn best evidence cho từng Applications_of_AI_id và field. Evidence được sort theo locked country rank, final_confidence, source_rank, depth và priority.

```
final_confidence = min(field_confidence + source_bonus, 1.0)
source_bonus: official/validation +0.20, csv/social +0.00
source_rank: validation -> official -> csv -> social -> other
sort tie-break: locked country first, higher confidence, lower depth, lower URL priority
```

rules.py quyết định action cho từng field: KEEP nếu không có evidence hoặc value giống gốc; ADD nếu gốc thiếu và confidence đủ; REPLACE nếu khác gốc và confidence $\geq$ replace_threshold; CONFLICT_REVIEW nếu khác gốc nhưng chưa đủ chắc.

Step 6: export-er-ready

data_enriched.csv là bản audit đầy đủ. data_er_ready.csv là bản gọn hơn để đưa vào Databricks/ER. ER-ready vẫn giữ input_company_name và các input_main_* để audit, đồng thời tạo các field chuẩn để matching.

- company_name: nếu original có thì giữ original; chỉ dùng final_company_name khi original thiếu.
- main_country_code/main_country: ưu tiên validation result nếu accepted và đủ confidence.
- main_city, primary_email, short_description: có threshold riêng trong er_ready config.
- year_founded và employee_count: add-only, nghĩa là original có thì giữ original; chỉ fill khi original thiếu và confidence đủ.

6. Output files

Output	Nội dung
dataset/silver/url_manifest.parquet	Tất cả URL seed sau normalize, kèm source_type, source_col, priority, company ID.
dataset/silver/crawl_queue.parquet	Queue deduplicated để crawler chạy.
dataset/silver/geo_prefill.parquet	Locked country evidence từ strong TLD.
dataset/silver/crawl_results_raw.parquet	Raw HTML/markdown/metadata/error theo từng page crawl.
dataset/silver/crawl_extracted_fields.parquet	Long-form evidence: mỗi row là một extracted field.
dataset/silver/company_validation_results.csv	Validation report cho country/city, gồm signals, vote, verdict và recommended_action.
dataset/silver/data_enriched.csv	Full enriched dataset, có final_* columns, action columns, evidence_json và actions_json.
dataset/silver/quality_report.parquet	Bảng đếm action theo field để audit chất lượng.
dataset/silver/data_er_ready.csv	File gọn, sạch, dùng cho Databricks/ER matching.

7. Ví dụ flow

Input row có company_name = ABC A/S, main_country_code trống, website_url = https://abc.dk, linkedin_url cũng có.

- build-manifest tạo official seed từ website_url và social seed từ linkedin_url.
- geo_prefill thấy .dk nên tạo locked evidence: main_country_code = DK, main_country = Denmark.
- crawl vẫn crawl website chính thức để lấy about/contact pages và crawl LinkedIn seed một trang nếu có thể.
- extract tìm thấy email info@abc.dk và founded year 2005 từ JSON-LD/body text.
- merge ADD country, ADD email/year nếu original thiếu; nếu company_name trên web khác original thì action có thể REPLACE hoặc CONFLICT_REVIEW theo confidence, nhưng ER-ready vẫn giữ original company_name nếu original có.
- export-er-ready tạo một row compact cho matching, kèm country_validation_verdict và source columns.

8. Lỗi thường gặp

- Execution context was destroyed: thường do trang redirect/reload khi Crawl4AI đang remove consent popup. Nếu page vẫn COMPLETE success thì có thể bỏ qua.
- BrowserContext.new_page / pipe closed by peer: Playwright/Chromium context bị đóng. Code hiện giảm rủi ro bằng crawl_batch_size để restart context theo batch.
- LinkedIn/Facebook/YouTube fail nhiều: social sites có anti-bot mạnh. Pipeline vẫn giữ social trong manifest nhưng không deep crawl để giảm rủi ro.
- Cloudflare JS challenge: website đang dùng Cloudflare anti-bot. Crawl4AI có thể retry nhưng vẫn bị chặn. Đây là cơ chế bảo vệ của website, không phải lỗi logic pipeline.
- net::ERR_NAME_NOT_RESOLVED: DNS không resolve được domain, ví dụ domain hết hạn, URL sai, website đã ngừng hoạt động, hoặc mạng không tìm thấy host. URL đó sẽ được ghi failure row và pipeline tiếp tục với các nguồn evidence khác.

Example DNS failure:

```
[ANTIBOT]. http://egeneration.com.bd | Error: Proxy direct failed:
Page.goto: net::ERR_NAME_NOT_RESOLVED at http://egeneration.com.bd/
```